π0.5 模型算子报告

1. 模型概述

π0.5 (PI05) 是 Physical Intelligence 开发的 VLA (Vision-Language-Action) 模型，核心创新是**异构数据联合训练**，实现开放世界泛化能力。

- **论文**: https://arxiv.org/abs/2504.16054
- **框架**: LeRobot (HuggingFace)
- **模型路径**: `/home/ubuntu/stephen/02-weight/pi05_libero/`
- **Tokenizer 路径**: `/home/ubuntu/stephen/02-weight/paligemma-3b-pt-224/`

---

2. 算子架构总览

2.1 输入输出

输入	形状	说明
`observation.images.image`	(B, 3, 256, 256)	相机1图像
`observation.images.image2`	(B, 3, 256, 256)	相机2图像
`observation.state`	(B, 8)	机器人状态
`task`	str	语言指令

输出	形状	说明
`action`	(B, 7)	机器人关节动作

2.2 核心组件

```
输入 → [视觉编码器] → [语言编码器] → [ Expert Action Decoder] → 动作
         (SigLIP)       (Gemma)       (Flow Matching)
```

---

3. 核心算子详解

3.1 PaliGemmaWithExpertModel

功能: 视觉-语言联合编码器，含动作 expert

组成:

组件	类型	参数量
`vision_tower`	SigLIP ViT	~400M

组件	类型	参数量
`language_model`	Gemma 2B	~2B
`gemma_expert`	Gemma 300M	~300M

代码位置: `lerobot/src/lerobot/policies/pi_gemma.py`

描述:

- `vision_tower`: 处理图像输入，输出视觉特征
- `language_model`: Gemma transformer，处理文本token
- `gemma_expert`: 动作预测分支，含 AdaRMSNorm

3.2 PiGemmaRMSNorm

功能: 自适应 RMS 归一化 (AdaRMS)

代码位置: `lerobot/src/lerobot/policies/pi_gemma.py:85`

```
class PiGemmaRMSNorm(nn.Module):
    def __init__(self, dim: int, eps: float = 1e-6, cond_dim: int | None = None):
        # cond_dim=None: 标准 RMSNorm
        # cond_dim!=None: 条件归一化 (scale, shift, gate)
```

参数量:

模式	参数量
标准	dim (weight)
AdaRMS	dim × 3 (linear)

3.3 Flow Matching Action Head

功能: 基于 Flow Matching 的动作生成

代码位置: `lerobot/src/lerobot/policies/pi05/modeling_pi05.py:551`

组成:

算子	输入	输出	说明
`action_in_proj`	(B, 50, 8)	(B, 50, 2048)	动作投影
`time_mlp_in`	(B, 2048)	(B, 2048)	时间嵌入
`time_mlp_out`	(B, 2048)	(B, 2048)	时间 MLP
`action_out_proj`	(B, 50, 2048)	(B, 50, 8)	输出投影

Flow Matching 损失:

```
x_t = t * noise + (1-t) * actions   # 噪声调度
v_t = model(x_t, t)             # 预测速度
loss = MSE(noise - actions, v_t)   # Flow 目标
```

3.4 图像预处理算子

代码位置: `lerobot/src/lerobot/policies/pi05/modeling_pi05.py:152`

```
def resize_with_pad_torch(images, height, width, mode="bilinear"):
    # 1. 按比例缩放图像
    # 2. 填充到目标尺寸
```

3.5 位置编码

Sinusoidal Pos Embedding (`modeling_pi05.py:81`):

```
def create_sinusoidal_pos_embedding(time, dimension, min_period, max_period):
    # 输出一组 sin-cos 位置编码
    # 用于动作时间步嵌入
```

RoPE (旋转位置编码):

- 继承自 Gemma 模型
- 用于自注意力机制

---

4. 训练算子配置

4.1 PI05Config 参数

参数	默认值	说明
`paligemma_variant`	`gemma_2b`	VLM 骨干
`action_expert_variant`	`gemma_300m`	动作 Expert
`chunk_size`	50	动作预测步数
`n_action_steps`	50	执行数
`num_inference_steps`	10	推理采样步数
`image_resolution`	(224, 224)	图像尺寸
`optimizer_lr`	2.5e-5	学习率
`gradient_checkpointing`	False	梯度 checkpoint

4.2 归一化模式

特征类型	归一化方式
VISUAL	IDENTITY (无)
STATE	QUANTILES
ACTION	QUANTILES

---

5. 推理流程

5.1 前向传播

```
1. embed_prefix(images, tokens)
   ↓
   图像 → SigLIP → 视觉embed
   文本 → Gemma → 语言embed
   ↓
2. embed_suffix(noise, timestep)
   ↓
   噪声 + 时间 → 动作embed + 时间embed
   ↓
3. PaliGemmaForward
   ↓
   [视觉emb, 语言emb] + [动作emb] → Transformer
   ↓
4. action_out_proj
   ↓
   输出动作 velocity
```

5.2 采样流程 (Flow Matching)

```
1. x_0 = noise (随机初始化)
2. for step in range(num_steps):
      t = 1 - step/num_steps
      v = denoise(x_t, t)
      x_{t+1} = x_t + dt * v
3. return x_last
```

---

6. 参数量统计

6.1 各组件参数量

组件	参数量	占比
SigLIP (vision)	~400M	~10%

组件	参数量	占比
Gemma 2B (language)	~2.5B	~60%
Gemma 300M (expert)	~700M	~17%
动作头	~2M	~0.05%
总计	**~4.14B**	100%

6.2 模型文件

```
pi05_libero/
├── model.safetensors    # 13.5GB (权重)
├── config.json         # 配置
├── policy_preprocessor.json
└── policy_postprocessor.json
```

---

7. 完整模型结构 (4.14B 参数)

```
pi05: PI05Pytorch (4143.4M)
  paligemma_with_expert: PaliGemmaWithExpertModel (4141.2M)
    paligemma: PaliGemmaForConditionalGenerationWithPiGemma (3450.0M)
      model: PaliGemmaModelWithPiGemma (2923.3M)
        vision_tower: SiglipVisionModel (412.4M)
          vision_model: SiglipVisionTransformer (412.4M)
            embeddings: SiglipVisionEmbeddings (1.0M)
              patch_embedding: Conv2d (0.7M)
              position_embedding: Embedding (0.3M)
            encoder: SiglipEncoder (411.5M)
              layers: ModuleList (26层, 每层15.2M)
                SiglipEncoderLayer:
                  layer_norm1: LayerNorm
                  self_attn: SiglipAttention (5.3M)
                    k_proj, q_proj, v_proj, out_proj: Linear
                  mlp: SiglipMLP (9.9M)
                    fc1, fc2: Linear
            post_layernorm: LayerNorm
        multi_modal_projector: PaliGemmaMultiModalProjector (2.4M)
        language_model: PiGemmaModel (2508.5M)
          embed_tokens: Embedding (526.6M)
          layers: ModuleList (18层, 每层110.1M)
            _PiGemmaDecoderLayerBase:
              self_attn: GemmaAttention (9.4M)
                q_proj: Linear (4.2M), k_proj: Linear (0.5M)
                v_proj: Linear (0.5M), o_proj: Linear (4.2M)
              mlp: GemmaMLP (100.7M)
                gate_proj, up_proj, down_proj: Linear (各33.6M)
              input_layernorm: PiGemmaRMSNorm
```

```
                post_attention_layernorm: PiGemmaRMSNorm
            norm: PiGemmaRMSNorm
            rotary_emb: GemmaRotaryEmbedding
            lm_head: Linear (526.6M)
      gemma_expert: PiGemmaForCausalLM (691.3M)
        model: PiGemmaModel (427.9M)
          layers: ModuleList (18层, 每层23.6M)
            _PiGemmaDecoderLayerBase:
              self_attn: GemmaAttention (4.7M)
              mlp: GemmaMLP (12.6M)
              input_layernorm: PiGemmaRMSNorm (AdaRMS, 3.1M)
              post_attention_layernorm: PiGemmaRMSNorm (AdaRMS, 3.1M)
          norm: PiGemmaRMSNorm (3.1M)
          rotary_emb: GemmaRotaryEmbedding
          lm_head: Linear (263.3M)
    action_in_proj: Linear (32→1024)
    action_out_proj: Linear (1024→32)
    time_mlp_in: Linear (1024→1024)
    time_mlp_out: Linear (1024→1024)
```

7.1 核心算子详解

模块	层数	每层参数量	总参数量	关键算子
SigLIP Vision	26	15.2M	412.4M	Conv2d, Attention, MLP
Gemma Language	18	110.1M	2508.5M	Attention, MLP, RMSNorm
Gemma Expert	18	23.6M	691.3M	Attention, MLP, AdaRMS
Action Head	-	-	~2M	Linear

---

8. 常见 LLM 算子对比

7.1 标准 LLM 算子

算子	功能	参数量公式
Embedding	token→向量	$V \times d$
Attention	自注意力	$4d^2$
FFN/MLP	前馈网络	$2 \times d \times 4d$
LayerNorm	归一化	d
RoPE	位置编码	无参数
LM Head	词表预测	$V \times d$

8.2 π0.5 特有算子

算子	功能	说明
PiGemmaRMSNorm	自适应归一化	条件 RMSNorm
Flow Matching	动作生成	连续动作预测
SinusoidalPosEmb	时间编码	动作时间步
Action Projection	动作投影	状态→动作

---

9. 参考资料

- 模型代码: `/home/ubuntu/stephen/01-code/lerobot/src/lerobot/policies/pi05/`
- 配置文件: `/home/ubuntu/stephen/01-code/lerobot/src/lerobot/policies/pi05/configuration_pi05.py`
- LeRobot: https://github.com/huggingface/lerobot
- OpenPI: https://github.com/Physical-Intelligence/openpi